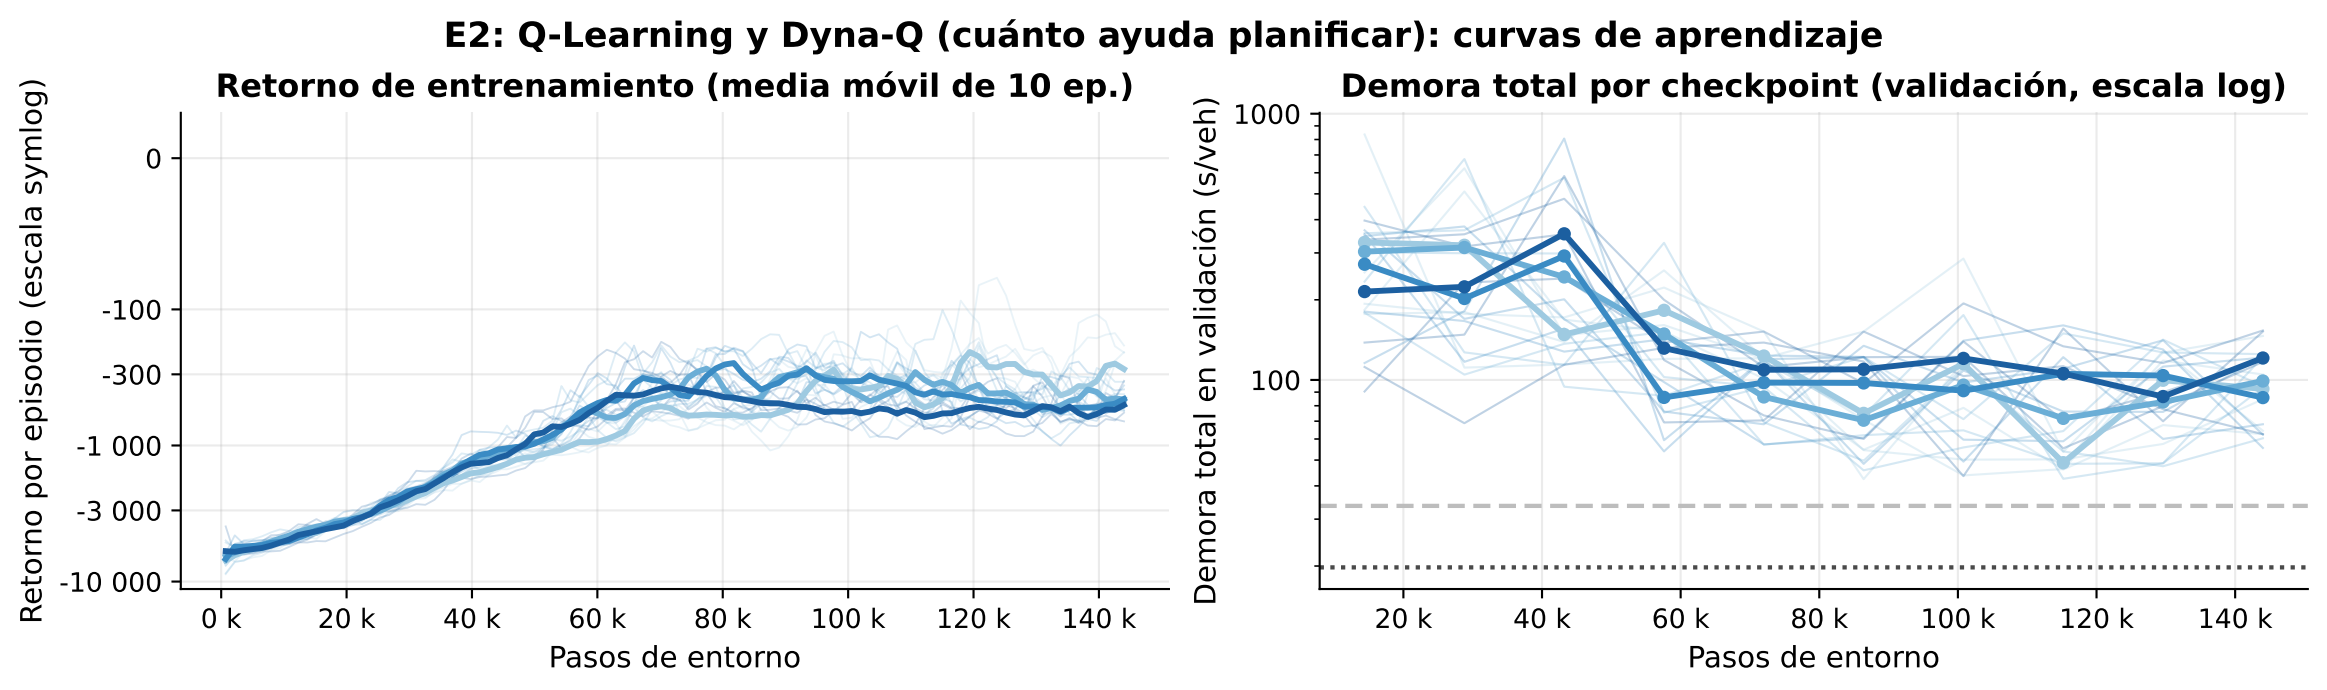

E2: Q-Learning y Dyna-Q (cuánto ayuda planificar): curvas de aprendizaje
Retorno de entrenamiento (media móvil de 10 ep.)
Retorno por episodio (escala symlog)
0
-100
-300
-1 000
-3 000
-10 000
0 k
20 k
40 k
60 k
80 k
100 k
120 k
140 k
Pasos de entorno
Demora total por checkpoint (validación, escala log)
Demora total en validación (s/veh)
1000
100
20 k
40 k
60 k
80 k
100 k
120 k
140 k
Pasos de entorno
Línea gruesa: media entre 5 semillas de entrenamiento (líneas finas: cada semilla; las de validación con 2 episodios). Líneas base: evaluación final, solo de referencia.
Q-Learning
Dyna-Q n=5
Dyna-Q n=10
Dyna-Q n=50
Tiempo fijo (evaluación)
Max-pressure (evaluación)