Oscilación de la validación entre checkpoints: agente único

Q-Learning | Dyna-Q n=5 | Dyna-Q n=10 | Dyna-Q n=50

DQN base | DQN + Double | DQN + Double + Dueling | DQN + Double + Dueling + PER

DQN mejor (E4) | PPO

Demora total (s/veh) — 1000 / 100 — Pasos de entorno — 20 k, 40 k, 60 k, 80 k, 100 k, 120 k, 140 k

Cada punto: demora total sobre 2 episodios de validación (semillas 2000 y 2001); escala vertical logarítmica.

★ checkpoint elegido — Tiempo fijo (evaluación) — Max-pressure (evaluación)