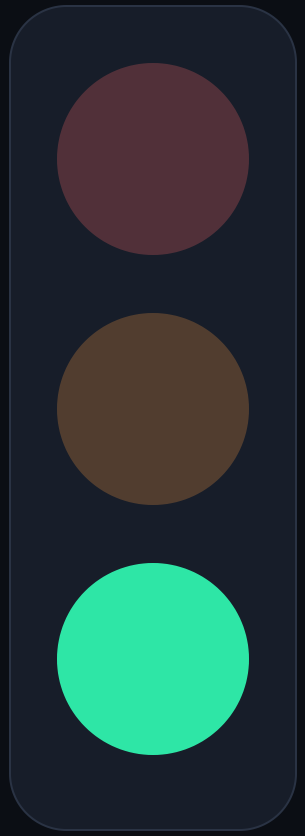
CC3104 APRENDIZAJE POR REFUERZO · UVG · 2026

Semáforos inteligentes en Av. La Reforma

Aprendizaje por refuerzo multiagente en un corredor real de 5 cruces



Integrantes: <completar>

El problema: semáforos que no ven la demanda

Los semáforos de tiempo fijo reparten el verde sin saber cuántos vehículos esperan en cada aproximación.

<dato: cifra de congestión en Ciudad de Guatemala con fuente verificable>

1.65 km — corredor en zonas 9 y 10

5 — semáforos consecutivos

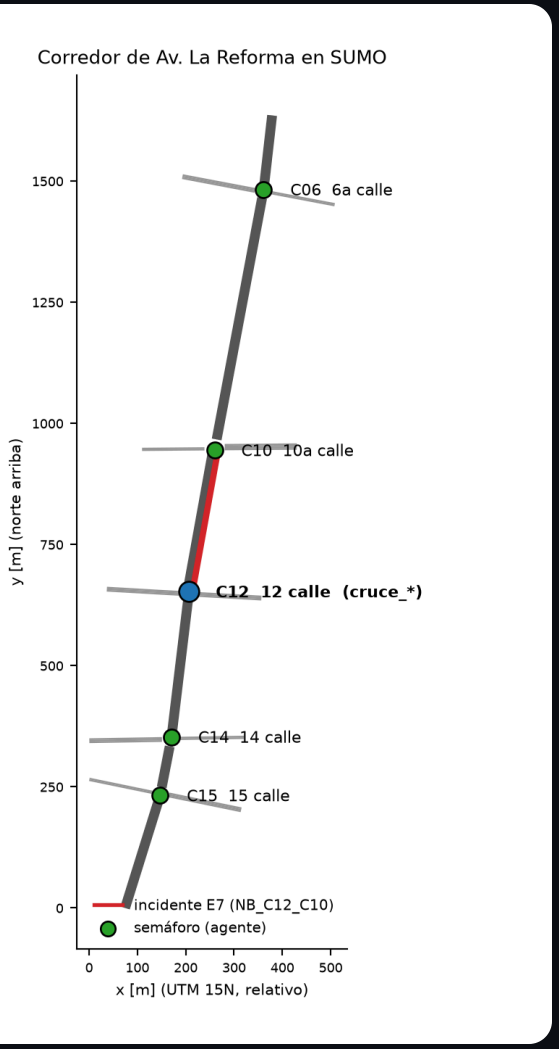
123–547 m — entre cruces: coordinación difícil

Pregunta de investigación

¿Cuánto reduce el RL multiagente el tiempo de espera en un corredor real de Guatemala frente al control actual, y se mantiene esa mejora ante condiciones que no vio en el entrenamiento?

- Frente a tiempo fijo y actuado
- Frente a max-pressure
- Hora no vista · +30 % · incidente

Escenario: corredor real de 5 cruces en SUMO



- **Red construida con geometría de OpenStreetMap**

  Sur a norte: 15, 14, 12, 10a y 6a calle; 3 carriles por sentido; transversales de una vía.

- **Cruce C12 (12 calle) para un agente**

  El más cargado; en rojo, el tramo del incidente de E7.

- **Datos sintéticos y provisionales**

  Conteos (7352 veh/h en el corredor en hora pico) y ciclo fijo de 110 s generados por script, no medidos en campo.

Formulación: MDP por cruce, Dec-POMDP en el corredor

Estado

Fase actual, verde mínimo cumplido, densidad y cola por carril (24 valores en C12).

Acción

Siguiente fase verde cada 5 s; el entorno impone amarillo de 3 s y verde mínimo de 10 s.

Recompensa

Reducción de la espera acumulada, incluida la de vehículos que esperan para entrar. $\gamma = 0.99$.

Dec-POMDP

5 agentes con observación local y recompensa de equipo; estado global solo al entrenar (CTDE).

Episodio: 3600 s simulados = 720 decisiones por agente.

Métodos: de reglas clásicas a RL multiagente

Líneas base
sin aprendizaje

- Tiempo fijo (Webster, 110 s)
- Actuado
- Max-pressure

Un agente
cruce C12

- Q-Learning
- Dyna-Q (n = 5, 10, 50)
- DQN + Double + Dueling + PER
- PPO

Multiagente
corredor de 5 cruces

- IDQN (+ colas de vecinos)
- QMIX
- MAPPO
- Comunicación (DIAL)

Más complejidad hacia la derecha · 3 líneas base y 16 configuraciones de RL con el mismo protocolo.

Hallazgo clave: el agente aprendía a bloquear una entrada

Con la recompensa estándar de sumo-rl, los autos que no caben en el carril esperan fuera de la red sin costo.

	Tiempo fijo	DQN original	DQN corregido
Espera media	29.2 s	**14.9 s**	19.7 s
No entró (backlog)	0.21 %	**4.92 %**	0.46 %
Demora total	31.6 s	**97.1 s**	**34.4 s**

Cruce C12, 40 episodios de entrenamiento, 3 semillas de evaluación (corridas de sanidad).

Corrección

- La recompensa suma la espera de los pendientes de entrar
- Métrica principal: demora total por vehículo demandado

La espera media premiaba el atajo; la demora total lo castiga.

Protocolo: mismo presupuesto, semillas separadas

1 Entrenar

5 semillas × 200 episodios = 144 000 decisiones por agente

2 Validar

Checkpoint cada 20 episodios; se elige el mejor con semillas 2000 y 2001

3 Evaluar

10 episodios nunca vistos (semillas 1000 a 1009)

4 Comparar

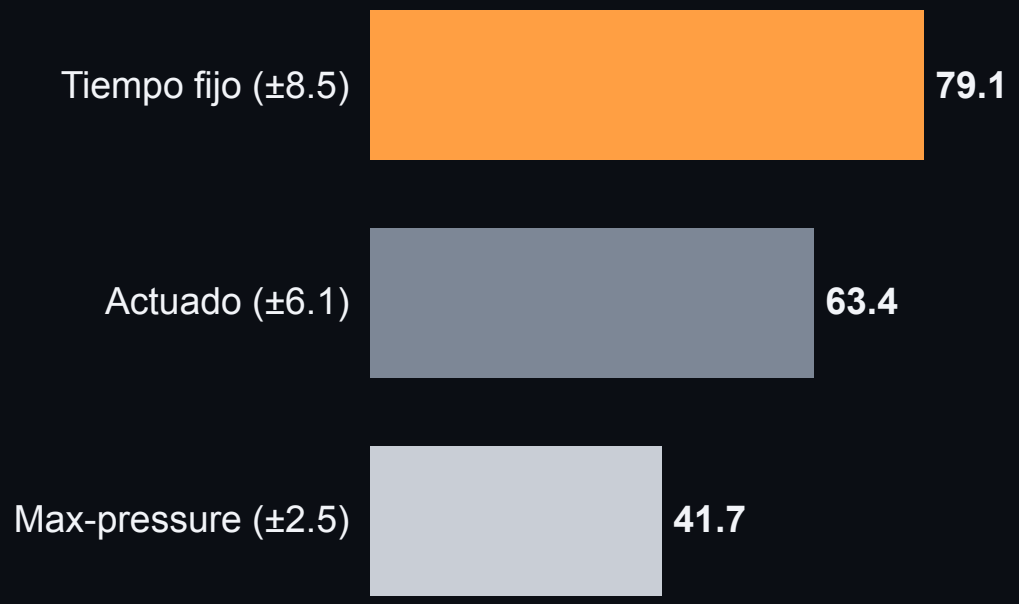
Media ± IC95; t de Welch con corrección de Holm

Métrica principal: demora total (s/veh demandado)

Espera en la red + retraso de inserción + espera afuera de quienes nunca entraron.

E1 · Max-pressure es una línea base muy fuerte

Corredor, hora pico · demora total (s/veh)



Media ± IC95 entre 10 episodios de evaluación.

−47 %

max-pressure frente al fijo en el corredor (41.7 vs 79.1 s)

−41 %

en el cruce C12 (19.8 vs 33.6 s)

12.7–15.7 %

de la demanda no entra con +30 % de demanda

E2–E4 · Un cruce: DQN y PPO cerca de max-pressure

Cruce C12, hora pico · demora total (s/veh)



DQN completo = Double + Dueling + PER. Media de 5 semillas (líneas base: 10 episodios).

E2 · Planificar no ayudó

Dyna-Q n=50: +8.2 s frente a Q-Learning (p = 0.16); ningún tabular alcanza al fijo.

E3 · Variantes de DQN en el ruido

Completo frente a base: −1.6 s (p = 0.23).

E4 · DQN ≈ PPO

PPO +2.8 s (p = 0.10); ambos sin diferencia detectable con max-pressure.

E5–E6 · MAPPO mejora al fijo, no a max-pressure

Corredor, hora pico · demora total (s/veh)



Media ± IC95 entre 5 semillas de entrenamiento (líneas base: 10 episodios).

−41 %

MAPPO frente al tiempo fijo (p Holm < 0.001)

+5.1 s frente a max-pressure

p = 0.13: sin diferencia detectable

Sin ola verde

Comunicación: 4.1 paradas/veh; líneas base: 2.7–3.9

E7 · La ventaja se pierde con +30 % de demanda

Corredor · s/veh	Pico	Mediodía	+30 %	Incidente
Tiempo fijo	79.1	30.4	345.7	198.4
Actuado	63.4	18.7	320.4	180.5
Max-pressure	41.7	21.1	**252.2**	**161.8**
MAPPO	**36.8**	**17.2**	**373.3**	165.5
Comunicación	**36.8**	20.7	281.8	175.2

Demora total media de 10 episodios. Agentes: una semilla por familia, elegida por validación (favorece a los agentes).

+48 %

MAPPO frente a max-pressure con +30 % de demanda (y +8 % frente al fijo)

×10.1 vs ×6.0

Degradación de la demora de pico a +30 %: MAPPO frente a max-pressure

E8 · En el cruce, menos demora cuesta equidad

Cruce C12 · espera máxima en la 12 calle (s)



Media de 5 semillas (líneas base: 10 episodios). +48 % a +140 % frente al fijo.

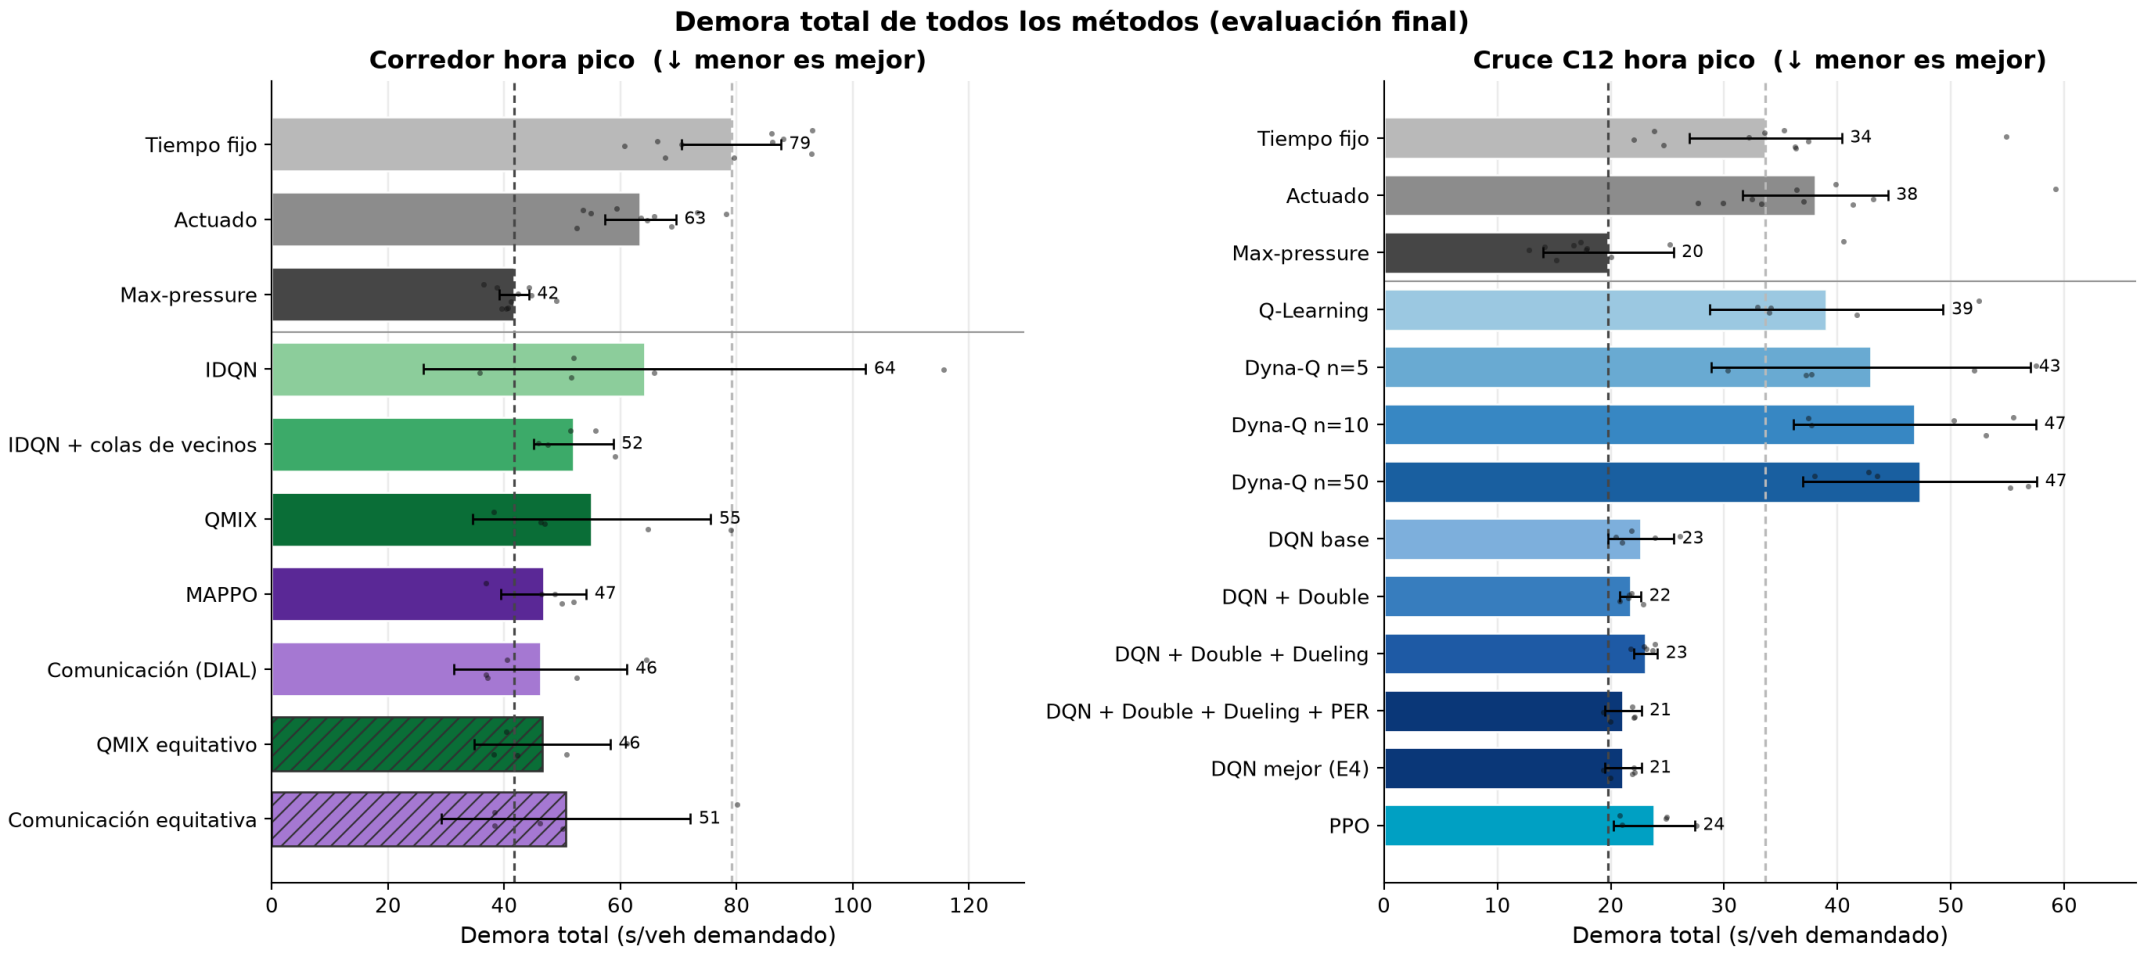
En el corredor, sin ese costo

Espera máxima en transversales: MAPPO 314 s, max-pressure 420 s, tiempo fijo 524 s.

CO_2 frente al tiempo fijo

Actuado −11.3 %, max-pressure −9.6 %; agentes aprendidos entre −8.4 % y +2.7 %.

Resumen: el RL vence al fijo, no a max-pressure



Demo en vivo: tiempo fijo contra MAPPO



- Dos simulaciones SUMO sincronizadas: misma demanda y semilla
- En vivo: inyectar autos, cambiar la hora, cerrar carriles
- «Mejora» = espera en vivo, no la demora total evaluada

Plan B: video de 3:46

Captura del video de respaldo: incidente en Reforma entre la 12 y la 10a calle.

Ética y limitaciones

Lo que el modelo no ve

- Peatones: fases mínimas como restricción dura
- Emergencias: prioridad por encima del agente
- Buses y motos: la recompensa cuenta vehículos, no personas

Limitaciones

- Conteos y ciclo fijo sintéticos
- 5 semillas: poco poder estadístico
- Detectores perfectos en simulación; brecha con la calle

¿Quién gana y quién pierde?

En el cruce gana quien va por Reforma; la espera máxima en la transversal sube hasta 140 % frente al fijo.

Conclusiones y trabajo futuro

1

Sí mejora frente al control actual

−41 % (MAPPO, corredor) y −37 % (DQN, cruce)

2

No supera a max-pressure

Ninguna diferencia a favor del RL

3

Se degrada fuera de lo entrenado

Con +30 % de demanda, MAPPO queda peor que el fijo

4

Medir bien cambia la conclusión

Demora total en lugar de espera media

Trabajo futuro

- Conteos reales en video y ciclos cronometrados
- Peatones, buses y motos
- Más semillas y demanda variable
- Max-pressure como respaldo (aprendizaje residual)

Declaración del uso de IA

Claude Code (Anthropic)

- Plan del proyecto y contratos entre módulos
- Código, pruebas y análisis, con agentes en ramas paralelas
- Borradores del informe y de esta presentación

Responsabilidad

El equipo revisó el código y los números, y responde por ellos.

<completar: qué se verificó a mano>

Plan › **Ramas en paralelo** › **Pruebas automáticas** › **Revisión humana**

¿Preguntas?

github.com/Alexistodj124/ProyectoFinalAR

CC3104 Aprendizaje por Refuerzo · UVG · 2026

